

The background is a solid dark gray. It features several thin, white, wavy lines that flow across the frame. A central black rectangle is positioned horizontally, containing the main text. The word "LABORATORIO" is written in a large, bold, white, sans-serif font, spanning most of the width of the rectangle.

LABORATORIO

2

CONTENIDO

- 01 Entendimiento de los datos
- 02 Búsqueda de relaciones con variable objetivo
- 03 Preparación de los datos
- 04 Entrenamiento de modelos
- 05 Analisis de resultados cuantitativo
- 06 Analisis de resultados cualitativo
- 07 Conclusiones y recomendaciones

ENTENDIMIENTO DE DATOS




En el entendimiento de los datos se vió que no hay variables categoricas, al ser solo numéricas, se hicieron scatterplot, histogramas y boxplot para analizar las relaciones de las variables numericas.




Se realizó un análisis de calidad de los datos, confirmando que no hay filas duplicadas. Se identificaron 313 valores faltantes en la columna PAGOS_MINIMOS y un dato faltante en LIMITE_CREDITO, aunque este último no es significativo en relación con el tamaño del conjunto de datos. En cuanto al análisis de consistencia, se encontraron 3,040 valores fuera del rango esperado en F_AVANCE_EFECTIVO, mientras que ninguna columna presenta valores negativos, lo que indica que los datos son consistentes con las especificaciones del diccionario de datos.


BUSQUEDA DE RELACIONES CON VARIABLE OBJETIVO




BUSQUEDA DE RELACIONES CON VARIABLE OBJETIVO



BUSQUEDA DE RELACIONES CON VARIABLE OBJETIVO




INTERPRETACIÓN DE LAS GRÁFICAS



Los gráficos de dispersión revelan patrones distintos entre variables como saldo, compras y pagos, donde se observa que algunos clientes tienen un comportamiento de compra frecuente pero pagos mínimos, mientras que otros hacen compras grandes esporádicamente. Los histogramas muestran que las frecuencias de compras y pagos se distribuyen de manera variada, lo que indica que los clientes tienen distintos hábitos financieros. Además, el uso de avances en efectivo está concentrado en algunos grupos, lo que sugiere una mayor dependencia del crédito en ciertos clientes.

BUSQUEDA DE RELACIONES CON VARIABLES DE ENTRADA



INTERPRETACIÓN DEL HEATMAP



El heatmap de correlación muestra que SALDO, AVANCE_EFECTIVO y PAGOS están altamente correlacionados, lo que sugiere posible redundancia en la segmentación de clientes. Además, F_SALDO, COMPRAS_PLAZOS y MESES_CLIENTE presentan una relación fuerte, indicando que clientes con mayor historial tienden a realizar compras a plazos. F_COMPRAS y PAGOS_MINIMOS también muestran una asociación significativa, lo que podría diferenciar clientes que compran con frecuencia pero pagan montos mínimos. Estas correlaciones deben considerarse para evitar sesgos en el modelo de agrupación.



PREPARACIÓN DE DATOS

1

LLENAR VALORES NULOS

Se identificaron 313 filas con valores faltantes en la columna de PAGOS_MINIMOS, estos datos faltantes fueron tllenados con la media de la clase.

2

ELIMINAR VALORES INCONSISTENTES


Se eliminaron los valores que estaban fuera del rango en la variable F_AVANCE_EFECTIVO

3

ESCOGER VARIABLES

Se seleccionaron SALDO, COMPRAS y AVANCE_EFECTIVO porque reflejan el uso del crédito, mientras que LÍMITE_CREDITO y PAGOS diferencian la capacidad de pago. MESES_CLIENTE indica antigüedad, y F_COMPRAS, F_PAGOS_COMPLETOS y F_AVANCE_EFECTIVO capturan patrones de frecuencia financiera.

RELACIONES DE VARIABLES ESCOGIDAS



INTERPRETACIÓN DEL HEATMAP




El heatmap muestra una alta correlación entre SALDO, AVANCE_EFECTIVO y MESES_CLIENTE, lo que indica que clientes con mayor saldo y antigüedad tienden a usar más avances en efectivo. F_COMPRAS y MESES_CLIENTE están fuertemente relacionadas, sugiriendo que clientes antiguos compran con mayor frecuencia. La fuerte correlación negativa entre SALDO y F_PAGOS_COMPLETOS (-0.97) indica que quienes tienen mayor saldo suelen pagar menos completamente.


ENTRENAMIENTO DEL PRIMER MODELO

- Se entrenó un modelo de agrupación con K-Means y se determinó el número óptimo de clusters utilizando el método del codo, obteniendo $K=3$. Se realizaron pruebas con más y menos clusters, y los resultados confirmaron que tres grupos proporcionaban la mejor segmentación. Con valores mayores o menores de K , se observaron clusters mal definidos, algunos demasiado agrupados y otros fragmentados dentro del mismo grupo, validando la elección.


RESULTADOS DEL PRIMER MODELO



RESULTADOS DEL PRIMER MODELO



RESULTADOS DEL PRIMER MODELO



CONCLUSIONES DEL PRIMER MODELO


- El primer modelo mostró buenos resultados, con un coeficiente de silueta de 0.8, indicando un agrupamiento adecuado entre los clusters. Las variables seleccionadas reflejan tres tipos de comportamiento en los clientes, permitiendo al negocio realizar una segmentación clara. Esto facilita la creación de campañas de marketing ajustadas a las preferencias y hábitos de cada grupo, optimizando las estrategias comerciales.

ENTRENAMIENTO DEL SEGUNDO MODELO

- Se entrenó un modelo de agrupación HAC, el cual también es conocido como “bottom-up approach”. Este maneja la información de tal forma que dato es único desde el principio y luego aglomeran sucesivamente pares de grupos hasta que todos los grupos se han fusionado en un solo grupo que contiene todos los datos.

RESULTADOS DEL SEGUNDO MODELO


PCA PROJECTION OF CLUSTERS



Mediante un análisis de componentes principales (PCA) podemos visualizar los patrones que existen en datos con múltiples variables. En este caso, cada punto representa un cliente y los colores indican los tres clusters identificados por el algoritmo de agrupación jerárquica.

Para FinanzasAlpes, esta clara separación de segmentos representa una oportunidad valiosa para personalizar sus estrategias comerciales y de servicio al cliente, adaptándolas a las necesidades y comportamientos específicos de cada grupo identificado.

CLUSTER PROFILES HEATMAP




El mapa de calor presenta los valores promedio de cada variable para los tres clusters identificados. La intensidad del color (azul más oscuro) indica valores más altos, mientras que los tonos más claros representan valores más bajos. Esta visualización nos permite comparar directamente las características de cada segmento de clientes.

Esta segmentación ofrece a FinanzasAlpes la oportunidad de:

- 1. Diseñar programas de fidelización y beneficios adicionales para los clientes del Cluster 0.
- 2. Implementar estrategias de gestión de riesgo y programas de pago para los clientes del Cluster 1.
- 3. Desarrollar ofertas de consolidación de deuda o reestructuración financiera para los clientes del Cluster.

Esta diferenciación clara permite a la empresa adaptar su comunicación, productos y estrategias de riesgo según las necesidades y comportamientos específicos de cada segmento de clientes.

RADAR CHART OF CLUSTER PROFILES



El gráfico radar (o de telaraña) ofrece una representación visual de los perfiles normalizados de cada cluster a través de todas las variables analizadas. Cada eje representa una característica diferente, y las líneas de colores muestran cómo se comporta cada segmento en relación con estas variables. Este tipo de visualización permite identificar rápidamente las fortalezas y debilidades relativas de cada grupo de clientes.

El gráfico radar no solo confirma los perfiles identificados anteriormente, sino que también visualiza de manera impactante las diferencias entre los tres segmentos, facilitando la comunicación de estos hallazgos a los equipos de marketing, riesgo y servicio al cliente de FinanzasAlpes para el desarrollo de estrategias específicas y efectivas para cada grupo.


CONCLUSIONES SOBRE HAC

- Alta calidad de segmentación: El puntaje de silueta de 0.806 para la solución de tres clusters indica una separación clara y coherente entre los segmentos identificados, lo que confirma la robustez del modelo.
- Interpretabilidad superior: Los tres segmentos identificados presentan perfiles claramente diferenciados y con significado de negocio, facilitando la traducción de los resultados técnicos en acciones comerciales concretas.
- Visualización reveladora: La proyección PCA muestra una separación espacial contundente entre los tres grupos, confirmando que no existe solapamiento significativo entre los perfiles de clientes.
- Consistencia interna: La compacidad de los clusters en las visualizaciones indica homogeneidad dentro de cada segmento, lo que permite desarrollar estrategias específicas con mayor confianza.
- Distribución significativa: La distribución de clientes entre los segmentos (55.6%, 32.9% y 11.5%) es equilibrada y significativa desde el punto de vista de negocio, permitiendo acciones masivas para los segmentos mayoritarios y estrategias focalizadas para el segmento minoritario.

ENTRENAMIENTO DEL TERCER MODELO DBSCAN


- DBSCAN es un algoritmo que va eligiendo centroides dependiendo de cuantos otros datos hay en un cierto radio dado, si el numero de datos supera un minimo dado en los hiperparametros, se construye un cluster con ese centroide. El algoritmo es muy bueno para trabajar con datos a los cuales no se sabe bien el numero de clusters a asignar y maneja muy bien el ruido, haciendo un cluster de outliers. Sin embargo es importante recalcar que el numero de clusters final lo decide el algoritmo y no el programador. Para este caso, se hicieron varias pruebas con distintos hiperparametros hasta encontrar la que tuviera el mejor promedio de coeficiente de silueta.

RESULTADOS DEL TERCER MODELO




RESULTADOS DEL TERCER MODELO

***LOS
PAIRPLOTS SE
VEN EN SU
TOTALIDAD EN
EL NOTEBOOK**



RESULTADOS DEL TERCER MODELO



RESULTADOS DEL TERCER MODELO



ANÁLISIS CUANTITATIVO TERCER MODELO

- El Coeficiente de silueta nos indica que 0.7789. Dado que es un valor alto, significa que los puntos están bien agrupados y separados del resto, lo que sugiere que DBSCAN ha hecho un buen trabajo detectando las estructuras en los datos. Cabe resaltar que técnicamente hay 4 clusters, pero el primero se refiere a los outliers, que se puede evidenciar que DBSCAN no observó muchos

ANÁLISIS CUALITATIVO TERCER MODELO

- Se puede ver que los clusters asignados, que fueron 3, funcionan bien para la mayoría de columnas, y no hay casi overlap entre estos. Los grupos formados son por lo general compactos y bien definidos. Adicionalmente, los outliers son muy pocos, lo cual es bueno para el modelo. Podemos ver que los clusters tienen características definidas, como que el grupo 1 tiende a hacer muchas más compras que los demás, o que el grupo 0 es el que más pagos realiza y menos saldo tiene. Todo esto indica que los grupos son un buen apoyo para la empresa para poder caracterizar mejor a sus clientes y armar planes más personalizados para estos grupos.

CONCLUSIONES



Los tres modelos son utiles para el caso, pero modelo más adecuado en terminos generales es el modelo de HAC, pues es el que mejor puntaje tiene en el coeficiente de silueta, y sus clusters están muy bien definidos.

CONCLUSIÓN 1



Se identificaron tres grupos predominantes en los datos:
Clientes Estables y Cumplidores, Grandes Consumidores con Alto Riesgo y Usuarios de Avance Efectivo con Alto Endeudamiento

CONCLUSIÓN 2



Si bien los modelos funcionan muy bien con los datos dados, al ser un modelo no supervisado es importante probar los modelos con una variedad más grande de datos.

CONCLUSIÓN 3